Predicción de precios de alojamientos de Airbnb

Informe técnico · Ciencia de Datos · Trabajo final grupal

1. Introducción y objetivo

El objetivo de este trabajo es estimar el precio por noche de publicaciones de Airbnb a partir de características observables del alojamiento. Para ello, realizamos primero un análisis exploratorio de datos (EDA) y luego entrenamos distintos modelos de regresión. Finalmente comparamos sus errores de predicción y evaluamos el efecto de reducir la dimensionalidad con PCA.

2. Descripción del conjunto de datos

Partimos de un archivo con 19.309 publicaciones y 29 variables. Las propiedades se encuentran en San Francisco (SF), Washington DC (DC), Chicago y Boston. La variable que buscamos predecir es price, expresada en dólares por noche. Entre las posibles variables explicativas están la ciudad, el tipo de habitación, los dormitorios, los baños, la capacidad y la ubicación geográfica.

Dato	Valor
Publicaciones	19.309
Variables originales	29 (incluida price)
Ciudades	4
Precio medio / mediano	USD 195,23 / USD 135,00

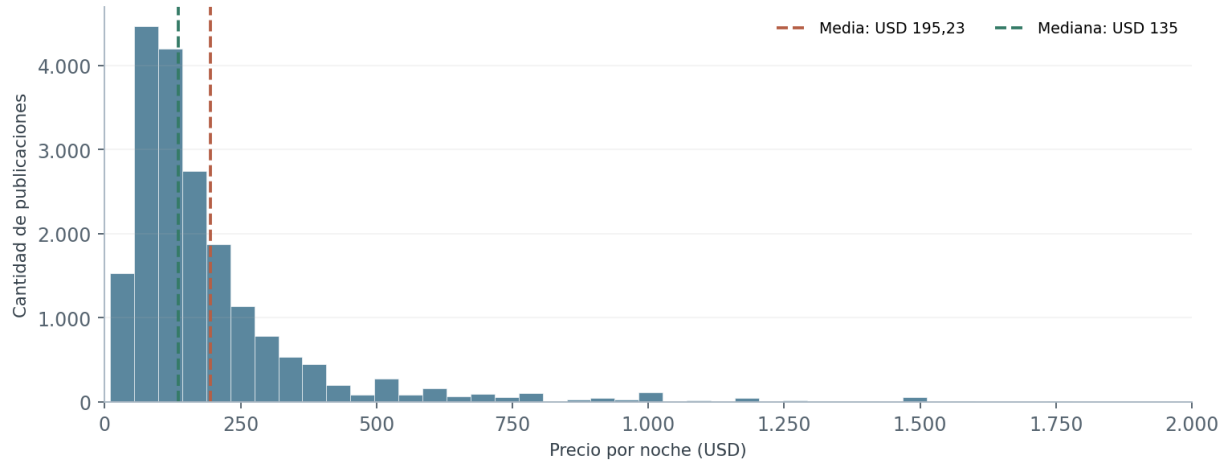


Figura 1. Distribución de precios del dataset original (elaboración propia).

La distribución no es simétrica: predominan precios relativamente bajos y existen algunas propiedades mucho más caras. Por eso, además del promedio, es útil observar la mediana y los valores extremos.

3. Análisis exploratorio de datos (EDA)

Revisamos los tipos de datos, la presencia de duplicados, los valores faltantes y la relación del precio con distintas características. No encontramos filas duplicadas. Se detectaron variables que no tienen incidencia directa con PRECIO, entonces se eliminan de los datos.

Diferencias de precios

El precio medio varía según la ciudad y el tipo de alojamiento. San Francisco y Washington DC presentan promedios superiores a Boston y Chicago. Las viviendas completas también muestran precios medios mayores que las habitaciones privadas o compartidas.

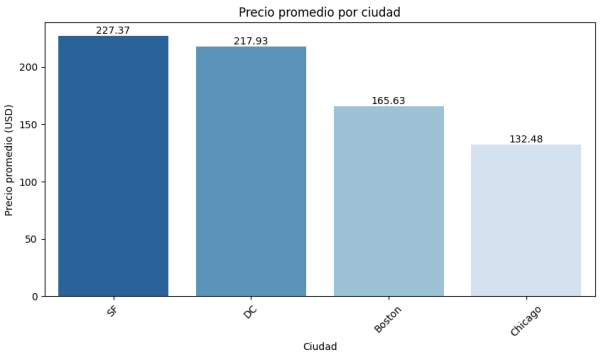


Figura 2. Precio medio por ciudad.

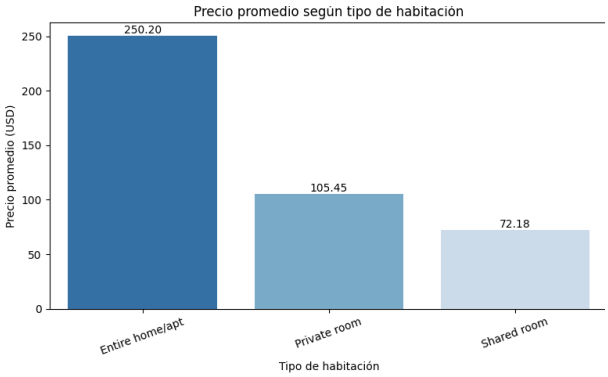


Figura 3. Precio medio por tipo de habitación.

Valores faltantes y extremos

Variable	Faltantes	% del total
host_response_rate	4.296	22,25 %
review_scores_rating	4.134	21,41 %
neighbourhood	1.458	7,55 %
bathrooms	35	0,18 %

El primer cuartil del precio fue USD 87 y el tercero USD 220. Aplicando la regla de 1,5 veces el rango intercuartílico, se identificaron 1.570 publicaciones por encima del umbral superior de USD 419,50 (8,13 %). Son valores atípicos desde un criterio estadístico, pero no necesariamente errores, por lo que se conservaron.

Relación con variables numéricas

Las correlaciones positivas más altas con price fueron accommodates (0,44), bedrooms (0,44), beds (0,37) y bathrooms (0,37). Son relaciones moderadas que sugieren que la capacidad y el tamaño pueden aportar información para predecir precios. La correlación, por sí sola, no demuestra causalidad.

4. Materiales y métodos

Preparación de datos

Desde el archivo original se eliminaron siete columnas (identificador, textos extensos, fechas de reseñas, URL y código postal), obteniendo airbnb_clean.csv con 22 columnas. En el notebook de Machine Learning se descartaron además amenities y host_since para simplificar, por lo que se utilizaron 19 variables predictoras y price como respuesta.

La columna host_response_rate se convirtió de porcentaje en texto a número y cleaning_fee se representó con 0/1. Luego se dividió el conjunto de datos en 80 % para entrenamiento (15.447 filas) y 20 % para prueba (3.862 filas). La imputación, el escalado y la codificación de variables categóricas se hicieron dentro de un Pipeline, ajustado solamente con los datos de entrenamiento.

Modelos evaluados

Modelo	Idea principal
Referencia (media)	Predice el precio promedio de entrenamiento.
Regresión lineal	Relaciona el precio con una combinación lineal de variables.
Ridge	Regresión lineal con regularización de coeficientes.
Random Forest	Promedia predicciones de varios árboles de decisión.
Ridge + PCA	Ridge luego de reducir variables mediante componentes principales.

Diseño experimental

Se eligió el parámetro alpha de Ridge mediante GridSearchCV con tres particiones de validación cruzada; el mejor valor de la grilla fue 10. Random Forest se entrenó con 60 árboles, profundidad máxima 16 y un mínimo de tres observaciones por hoja; esos valores se fijaron por practicidad, sin una búsqueda exhaustiva.

Para la reducción de dimensionalidad se aplicó PCA después del preprocesamiento, conservando al menos el 95 % de la variabilidad de las entradas. Se obtuvieron 35 componentes principales, que representaron el 95,08 % de la variabilidad. Los resultados se midieron mediante RMSE, MAE y R^2.

5. Experimentos y resultados

Modelo	RMSE (USD)	MAE (USD)	R^2
Referencia (media)	215,51	126,55	0,00
Regresión lineal	171,62	95,26	0,37
Ridge	170,52	94,26	0,37
Random Forest	156,73	76,73	0,47
Ridge + PCA	173,06	96,88	0,35

Tabla 1. Desempeño sobre el conjunto de prueba. En RMSE y MAE un valor menor es mejor; en R^2, uno mayor.

5. Resultados (continuación)

Random Forest obtuvo el menor RMSE en prueba (USD 156,73) y el menor MAE (USD 76,73). El R^2 de 0,47 indica que el modelo explica aproximadamente el 47 % de la variación del precio observada en este conjunto de prueba. Esto no representa un 47 % de predicciones correctas.

Validación cruzada

Modelo	RMSE medio (USD)	Desvío estándar (USD)
Regresión lineal	158,20	4,53
Ridge	156,37	3,76
Random Forest	143,12	4,27

Tabla 2. Validación cruzada en tres particiones sobre el conjunto de entrenamiento. Random Forest volvió a presentar el menor error promedio. Los resultados corresponden a las configuraciones utilizadas en el notebook.

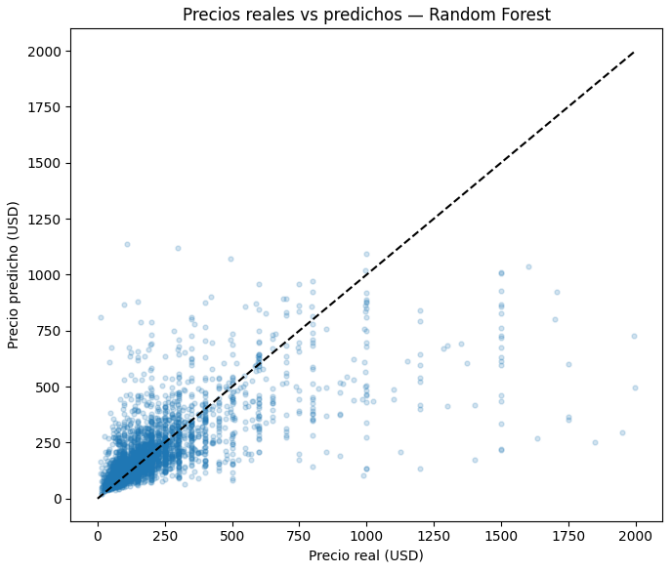


Figura 4. Precio real frente a precio predicho por Random Forest (gráfico generado en el notebook).

6. Discusión y conclusiones

Dentro de los modelos probados, Random Forest funcionó mejor que los modelos lineales. Sin embargo, el error sigue siendo considerable: el gráfico muestra que las propiedades de precio alto tienden a quedar subestimadas. El resultado no permite asegurar que el mismo modelo funcionaría igual en otras ciudades o con datos más recientes.

La prueba con PCA redujo mucho la cantidad de dimensiones, pero aumentó el RMSE de Ridge de USD 170,52 a USD 173,06. Por lo tanto, en este experimento simplificó la representación de los datos, aunque no mejoró la predicción. Como posibles mejoras se podrían recuperar algunas características descartadas y ajustar con más detalle los hiperparámetros.

7. Referencias

James, G., Witten, D., Hastie, T., Tibshirani, R. y Taylor, J. (2023). An Introduction to Statistical Learning: With Applications in Python. Springer.

Géron, A. (2022). Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow (3.ª ed.). O'Reilly Media.

Murphy, K. P. (2022). Probabilistic Machine Learning: An Introduction. MIT Press.